

特許文書の課題・解決手段分離に基づく クロスドメイン技術候補抽出

Cross-Domain Technology Candidate Extraction
Based on Separating Problems and Solutions in Patent Documents

鳥井 春風

卒業論文発表

2027年2月

アジェンダ

1. 研究背景・問題意識
2. 研究目的と提案手法の概要
3. 提案手法の詳細（文脈分離・GapScore）
4. 実験1：近接解決策型候補抽出（主分析）
 - データセット設計・期間設定
 - U-Netの出現傾向
 - 候補抽出結果・ベースライン比較
5. 実験2：異質解決策型候補抽出（補助分析）
 - S1クラスター・C1候補母集団
 - 評価結果・クラスター別分析
6. 考察・貢献・限界
7. まとめ

1. 研究背景・問題意識

異分野技術探索における課題

研究背景

なぜ異分野技術探索が必要か

- 企業・研究機関は **自分たちの分野の外** にある技術手法を参照することで、新しい問題解決の糸口を得る場合がある
- 例：画像解析，材料処理，洗浄，検査，制御……**対象物が違っても課題が近いことがある**
- 特許文書は技術の名称・課題・解決手段・効果を含む **豊富な知識源**

特許文書を使う利点

情報の種類	内容
タイトル	発明の概要
要約（Abstract）	目的・構成の要約
クレーム（Claims）	権利範囲・技術構成の詳細

→ キーワード検索だけでなく， **課題と解決手段の関係**を読み取れる

問題意識

全文類似の限界

全文をまとめてベクトル化すると、課題・対象物・解決手段・効果が**同一の表現空間に混在**し、候補が抽出された理由を説明しにくい

具体的な問題

1. **語彙の違い問題**：「医療画像」「製造欠陥」「半導体基板」など分野固有語が類似度に強く影響
2. **理由の不明瞭さ**：全文として似ていても、「課題が近いから？」「対象物の用語が似ているから？」かが不明
3. **有望候補の見落とし**：対象物や分野名は違うが課題が近い候補が、全文類似だけでは上位に現れにくい

💡 専門家が候補を確認する際、「**なぜこの候補を見るべきか**」を理解できる形で提示することが重要

2. 研究目的と提案手法の概要

研究目的

本研究が解く問い

「あるドメインAで広く用いられている技術手法は、類似した課題構造を持つドメインBにおいて、将来的に出現増加する候補となりうるか？」

本研究のアプローチ

特許文書を `problem_context`（課題文脈）と `solution_context`（解決手段文脈）に分離し、

- 課題が近い異分野間において
- 対象分野では **低出現または未使用** である技術手法・解決手段を
- **専門家が確認すべき候補** として抽出する

△ 本研究は技術導入可能性を証明するものではない。専門家確認候補を絞り込むスクリーニング手法として位置づける

提案手法の全体フロー

特許文書

(Title / Abstract / Claims)



LLMによる文脈抽出

problem_context	← 「何の課題を解いているか」
solution_context	← 「どのように解いているか」
technical_means	← 具体的手法名・構成要素
target_object	← 対象物
effect_context	← 効果・改善点



PatentSBERTa によるベクトル化
(文脈ごとに768次元ベクトルを生成)



課題文脈類似度 × Method_Gap × 頻度重み × 低出現ボーナス

GapScore



専門家確認候補ランキング → LLM支援付き著者確認評価

3. 提案手法の詳細

GapScoreの計算方法

文脈抽出：課題と解決手段の分離

抽出項目の定義

フィールド	意味	例（医療画像解析）
<code>problem_context</code>	何の課題を解いているか	「腫瘍領域の精密な分割が困難」
<code>solution_context</code>	どのように解いているか	「U-Netによるエンコーダ-デコーダ構造を用いた」
<code>technical_means</code>	具体的な技術手段・手法名	U-Net, GAN, Transformer
<code>target_object</code>	技術が適用される対象物	CT画像, MRI, 病変組織
<code>application_field</code>	応用分野	医療診断支援, 放射線科
<code>effect_context</code>	得られる効果	セグメンテーション精度の向上

分離の意義

全文類似では「医療画像 ↔ 欠陥画像」の**対象物の違い**が影響するが、`problem_context`に絞れば「**画像中の異常領域を検出する**」という課題の近さを捉えやすい

ベクトル化と類似度計算

PatentSBERTa によるベクトル化

特許特化型言語モデル **PatentSBERTa** (Sentence-BERTの特許ドメインFine-tune版) を使用

$$\mathbf{e}_i^{\text{problem}} = \text{PatentSBERTa}(\text{problem_context}_i) \in \mathbb{R}^{768}$$

ドメイン代表ベクトル (各ドメインの平均ベクトル) :

$$\bar{\mathbf{e}}_{A_0}^{\text{problem}} = \frac{1}{|A_0|} \sum_{i \in A_0} \mathbf{e}_i^{\text{problem}}$$

コサイン類似度でドメイン間の課題構造の近さを定量化 :

$$\text{sim}(A_0, B_0) = \cos\left(\bar{\mathbf{e}}_{A_0}^{\text{problem}}, \bar{\mathbf{e}}_{B_0}^{\text{problem}}\right)$$

フォールバック : `sentence-transformers/all-MiniLM-L6-v2`

GapScore の定義

Method Gap（手法ごとの出現率差）

手法 m について、 A_0 と B_0 の過去期間の出現率差：

$$\text{gap}_m = \text{rate}_{A,m} - \text{rate}_{B,m}$$
$$\text{rate}_{A,m} = \frac{|\{d \in A_0^{\text{past}} : m \in d\}|}{|A_0^{\text{past}}|}$$

GapScore（提案手法）

$$\text{GapScore}_m = \underbrace{\text{sim}^{\text{prob}}(A_0^{\text{unet}}, B_0)}_{\text{課題類似度}} \times \underbrace{\frac{\text{gap}_m}{\max_j \text{gap}_j}}_{\text{正規化 Gap}} \times \underbrace{\log(1 + N_{A,m})}_{\text{頻度重み}} \times \underbrace{\min\left(\frac{1}{\text{rate}_{B,m} + \varepsilon}, C\right)}_{\text{低出現ボーナス}}$$

項	意味
課題類似度	A_0 のU-Net特許群の課題ベクトルと B_0 全体のコサイン類似度
正規化Gap	A_0 – B_0 の出現率差（ B_0 でまだ少ない手法を高評価）
頻度重み	A_0 での出現件数の対数（稀すぎる手法にペナルティ）
低出現ボーナス	B_0 出現が少ない手法ほど高スコア（探索価値が高い）

候補タイプの定義

近接解決策型（実験1・主分析）

- 課題文脈・解決手段文脈の両方が比較的近い異分野間の候補
- 例：医療画像解析 → 製造欠陥検出
 - 共通課題：「画像中の異常・欠陥領域を検出・分割する」
 - 対象物は違うが手法が転用できる

異質解決策型（実験2・補助分析）

- 課題文脈に一定の関連はあるが、対象物・材料・工程・用途分野が大きく異なる候補
- 例：洗浄・除去系技術 → 半導体洗浄
 - 「洗浄・残渣除去」という課題は関連
 - 対象物や工程は大きく異なる

課題文脈類似度（Problem Similarity）が高く、解決手段文脈類似度（Solution Similarity）の差が大きい組み合わせが**候補抽出の対象**

4. 実験1：近接解決策型候補抽出

U-Netを対象とした主分析

実験1の設計

研究目的

医療画像解析で先行して現れたU-Netが、製造欠陥検出分野における**専門家確認候補として抽出できるか**を確認する（後ろ向き評価）

ドメイン定義

記号	分野	役割
A0	医療画像解析（Medical Image Analysis）	参照元ドメイン（技術供給源）
A1	A0のU-Net関連集合	U-Net出現確認用
B0	製造欠陥検出（Manufacturing Defect Detection）	対象ドメイン（候補探索先）
B1	B0のU-Net関連集合	U-Net出現確認用

期間分割

期間	年範囲	用途
過去期間（Past）	2015～2018年	候補抽出・ランキング生成に使用
将来期間（Future）	2019～2024年	後ろ向き評価（出現増加の確認）に使用

実験1のデータセット

データ概要（Orbis IPより取得）

データセット	公開公報数	ファミリー数
A0（医療画像解析・全体）	54,100件	30,093件
B0（製造欠陥検出・全体）	44,364件	28,450件

U-Net抽出条件

- Title または Abstract に **"U-Net"**, **"UNet"**, **"nnU-Net"**, **"U-Net++"**, **"UNet++"** を含むもの
- PublicationNumber（公開公報番号）が存在するレコードを1件としてカウント
- Family Identifier で重複除去

⚙ 技術的特記事項：xlsxのCentral Directoryが欠損していたため、Local File Headerを直接解析してsharedStrings.xml（展開後 ≈900MB）をストリーム解析（32MBチャンク）

U-Net出現傾向

分野別・期間別の出現状況

分野	集計単位	U-Net総件数	U-Net出現率	過去期間	将来期間
A0（医療画像解析）	公開公報	1,610件	3.0%	55件	1,555件
A0（医療画像解析）	ファミリー	1,133件	3.8%	33件	1,100件
B0（製造欠陥検出）	公開公報	314件	0.7%	0件	314件
B0（製造欠陥検出）	ファミリー	233件	0.8%	0件	233件

年次推移（出現率 %）

年	A0 U-Net率	B0 U-Net率	Gap
2015-2016	0.00%	≈0%	≈0
2017-2018	0.23~1.96%	0.00%	最大1.96%
2019-2021	3.50~4.87%	0.40~0.84%	3~4%
2022-2024	5.08~5.41%	0.65~1.22%	4~5%

→ A0で先行して増加し、B0では将来期間に出現が確認される。後ろ向き評価の前提が成立

実験1：候補抽出の流れ

データ処理パイプライン

A0_data.csv / B0_data.csv (Orbis IPから抽出)

↓

01. 前処理：Publication / Family レベルのCSV作成

↓

02. 手法抽出：U-Net, YOLO, GAN, Transformer 等の出現フラグ付与

↓

03. 文脈抽出：problem_context / solution_context の分離 (ルールベース + LLM補完)

↓

04. ベクトル化：PatentSBERTa による768次元ベクトル化

↓

05. 類似度計算：A0 vs B0 のコサイン類似度 (課題・解決手段・全文)

↓

06. Method Gap 計算：期間別・手法別の出現率差

↓

07. GapScore ランキング：過去期間のみの情報でランキング生成

↓

08. 後ろ向き評価：U-Netの順位確認 + B0将来期間での出現増加確認

↓

09. ベースライン比較：提案手法 vs 5種のベースライン

実験1：候補抽出結果

U-Net後ろ向き確認結果

項目	値	解釈
U-Netのランキング順位	2位	過去期間の具体的手法ランキングで上位に抽出
上位3件以内の抽出	該当	専門家確認候補として十分上位に含まれた
A0過去期間のU-Net出現件数	55件	医療画像解析分野（過去期間）で確認
B0過去期間のU-Net出現件数	0件	製造欠陥検出分野（過去期間）では未確認
B0将来期間のU-Net出現件数	314件	製造欠陥検出分野（将来期間）で出現・増加

✓ 後ろ向き評価の根拠：過去期間（2015-2018）の情報のみで、将来期間（2019-2024）に B0 で314件確認されることになる U-Netを**2位**に抽出できた

△ これは「将来の技術採用を当てた」のではなく、既知の後年出現を用いた**後ろ向き評価**である

実験1：ベースライン比較

各手法の評価結果（LLM支援付き著者確認評価）

候補タイプ	件数	平均スコア	妥当性率	◎	○	△	×
提案手法（GapScore）	23	1.61	52.2%	5	7	8	3
全文類似上位ベースライン	30	0.567	16.7%	1	4	6	19
頻度順ベースライン	30	2.27	76.7%	17	6	5	2
全文類似下位ベースライン	10	2.20	80.0%	4	4	2	0
U-Net関連集合	10	1.80	50.0%	4	1	4	1
ランダムサンプリング	30	2.07	66.7%	16	4	6	4

△ 頻度順・ランダム等はB0（製造欠陥検出）自体の候補を含むため高評価になりやすい。単純な精度比較ではなく、**候補集合の性質差**を確認する補助比較として解釈する

実験1：ベースライン比較の解釈

全文類似上位ベースライン との比較

全文類似上位ベースライン（30件）

- 妥当性率： **16.7%**（5件中1件強）
- × が **19件**（63%）
- 全文全体の類似だけでは、「医療画像 ↔ 欠陥画像」の対象物の違いが影響し、専門家確認候補として**弱い候補が多数混入**

提案手法（23件）

- 妥当性率： **52.2%**（2件中1件強）
- × が **3件**（13%）
- **problem_context** に絞ることで、課題の近さに基づいた候補が上位に出現
- 候補抽出理由を「課題が近い」「解決手段としてU-Net系技術が提示」と**説明しやすい**

提案手法の意義：単純な精度優位ではなく、**候補抽出理由の説明可能性**にある

実験1：まとめ

得られた知見

1. **U-Netの出現傾向**：医療画像解析（A0）で先行増加，製造欠陥検出（B0）では将来期間に出現確認 → 後ろ向き評価の前提が成立
 2. **候補抽出結果**：過去期間の情報のみで，U-Netを**2位にランキング**（上位3件以内）
 3. **ベースライン比較**：
 - 。全文類似上位ベースラインはxが多く，専門家確認候補として**弱い候補が混入しやすい**
 - 。提案手法は課題文脈ベースでxが少なく，**候補抽出理由を説明しやすい**
 4. **後ろ向き評価の意義**：B0の将来期間では0件→314件へ増加しており，過去期間での抽出が実際の出現増加と対応
-  近接解決策型の主分析として，課題文脈・解決手段文脈分離に基づく候補抽出が，専門家確認候補を整理するスクリーニング手法として有効に働く可能性が示唆された

5. 実験2：異質解決策型候補抽出

洗浄・除去系技術を対象とした補助分析

実験2の設計

目的・位置づけ

実験1（課題・解決手段ともに近い）に対し、**対象物や工程が大きく異なる場合**でも課題文脈を手がかりに候補を整理できるかを確認する補助分析

△ 本実験は花王の半導体分野への進出予測や、技術導入可能性を示すものではない

データ定義

記号	内容	役割
S1	花王の半導体洗浄関連既知事例	参照分野側（対象分野）の課題クラスタ作成に使用
S0	花王のその他洗浄・除去系技術	S1との比較・フィルタリング用
C1	非半導体系の洗浄・除去技術（C1候補母集団）	候補抽出の対象集合

処理の流れ

S1を1課題1クラスタ分類 → 各クラスタのproblem_contextベクトル化
C1を1課題1クラスタ分類 → problem_contextベクトル化
S0とC1を類似度でクラスター別ランキング（各クラスタ上位20件）
C1上位20件をS1上位20件と類似度比較（40件） → LLM支援付き結果提示評価

実験2：S1用途クラスタ

7つの用途クラスタ（S1の半導体洗浄既知事例を分類）

クラスタ	内容	クラスタ初出日の役割
接着剤洗浄	接着剤残渣の除去	C1候補抽出の時系列条件
回路基板洗浄	プリント基板等の洗浄	←
CMP後洗浄	化学的機械研磨後の残渣除去	←
フラックス・電子部品洗浄	フラックス残渣や電子部品洗浄	←
フォトレジスト・樹脂除去	レジスト・樹脂の除去	←
半導体基板洗浄	シリコン基板・半導体基板の洗浄	←
シリコンウェーハ洗浄	ウェーハ表面の洗浄	←

各クラスタ内S1の最早日を**クラスタ初出日**として設定し、それ以前に存在するC1候補を抽出（時系列制約）

C1候補母集団の作成条件

- 1. S1と同一ファミリーは**除外**（既知事例の再発見を避ける）
- 2. **半導体直接語**を含むものは除外（非半導体系候補に絞る）
- 3. **substrate** 単独は除外せず**確認用フラグ**として保持

実験2：評価結果（全体）

46件のユニークファミリーに対する LLM支援付き著者確認評価

ラベル	意味	件数	割合
◎	半導体洗浄・基板洗浄・残渣除去に直接接続しうる強い候補	11件	24%
○	精密洗浄・電子部品・材料表面処理等、周辺領域として接続しうる候補	5件	11%
△	課題・効果は近いが対象物・工程の対応が弱い候補	12件	26%
×	異質解決策候補としての対応が読み取りにくい候補	18件	39%
◎+○	強い or 妥当な専門家確認候補	16件	35%
◎+○+△	広義の確認候補	28件	61%

✓ 全体でノイズは多いが、46件中16件（35%）が強い or 妥当な専門家確認候補として解釈可能

△ ×が18件（39%）と多い。異質解決策型では洗浄対象・汚染物・工程条件の違いにより、候補が混入しやすい

実験2：クラスタ別評価結果

クラスタごとの評価結果の差

クラスタ	N	◎	○	△	×	◎+○	◎+○+△
接着剤洗浄	7	2	0	0	5	2	2
回路基板洗浄	3	1	1	1	0	2	3
CMP後洗浄	12	0	0	5	7	0	5
フラックス・電子部品洗浄	5	1	1	2	1	2	4
フォトレジスト・樹脂除去	6	2	0	2	2	2	4
半導体基板洗浄	6	5	1	0	0	6/6	6/6
シリコンウェーハ洗浄	7	0	2	2	3	2	4

✓ 半導体基板洗浄クラスタ：6件全て ◎ or ○
→ 対象・課題が比較的近いため良好

△ CMP後洗浄クラスタ：◎ ○ = 0件
→ CMP固有の工程性が強く、課題文脈だけでは対応が読み取りにくい

実験2：全文テキストベースラインとの比較

候補集合の重複・差分

比較対象	件数
提案手法（課題文脈ベース）	46件
軽量全文テキストベースライン	56件
重複するファミリー	11件
提案手法のみの候補	35件
ベースラインのみの候補	45件

重複11件の内訳：◎ 4件 / ○ 3件 / △ 2件 / × 2件

重複がわずか11件 → 課題文脈ベースと全文テキストベースは異なる候補集合を提示することを示す

解釈

- 全文テキストでは**対象物・用途語・請求項中の表現**が類似度に強く影響
- 課題文脈ベースでは**「何の課題に対応しているか」**に焦点
- どちらが優れているかではなく、**候補集合の傾向が異なる**という補助分析

6. 考察・貢献・限界

考察：課題・解決手段分離の有効性

全文類似との違い

全文類似アプローチ

- 課題・対象物・解決手段・効果が混在
- 候補が抽出された理由を説明しにくい
- 異分野間で対象物名・分野名の違いが強く影響

実験1検証：全文類似上位ベースライン
→ × が63%, 妥当性率**16.7%**

課題文脈分離アプローチ

- `problem_context`：「何の課題か」
- `solution_context`：「どう解くか」
- 候補抽出理由を分離して説明可能

実験1検証：提案手法
→ × が13%, 妥当性率**52.2%**

2種類の実験での確認

実験	タイプ	結果
実験1（主分析）	近接解決策型	U-Netを2位に抽出，後ろ向き評価と対応
実験2（補助分析）	異質解決策型	一部クラスタで有効，クラスタ依存性あり

本研究の貢献

4つの貢献

1. 文脈分離フレームワーク

特許文書を `problem_context` と `solution_context` に分離するフレームワークを提示。候補抽出理由を「課題が近い」「解決手段として〇〇が提示されている」として説明しやすくした

2. 近接解決策型の主分析（実験1）

U-Netを対象として、医療画像解析→製造欠陥検出への後ろ向き評価を実施。過去期間でランク2位を達成

3. 異質解決策型の補助分析（実験2）

洗浄・除去系技術から半導体洗浄への候補抽出を探索的に確認。クラスタ設計の重要性を示した

4. スクリーニング手法としての評価設計

LLM支援付き著者確認評価により、候補の解釈可能性を確認する評価体制を構築

本研究の限界

限界	内容
技術導入可能性	候補は専門家確認対象であり、実装・商用化・採用を保証しない
LLM抽出の誤差	<code>problem_context</code> 等は中間表現であり、常に正確とは限らない
評価の主観性	LLM支援付き著者確認評価であり、大規模な第三者専門家評価ではない
特許の限界	特許に記載された技術が必ずしも製品化・実装済みとは限らない
クラスタ設計依存	実験2では用途クラスタや語フィルタ設計が候補品質に大きく影響
ドメイン範囲	1ペアのドメイン組み合わせ（実験1）・1企業（実験2）のみ

今後の展望

- ・ 第三者専門家評価の導入による評価の厳密化
- ・ 他ドメイン（材料・エネルギー・医薬・化学プロセス等）への適用
- ・ 厳密な埋め込みベースラインとの比較
- ・ 技術導入可能性評価（実験的検証・市場面分析）との接続

7. まとめ

まとめ

本研究の全体像

特許文書を **problem_context**（課題文脈） と **solution_context**（解決手段文脈） に分離し，課題に近い異分野間で対象分野では低出現な技術手法を専門家確認候補として抽出するスクリーニング手法を提案・検証した

実験結果のまとめ

実験1（主分析：近接解決策型）

- A0（医療画像解析）→ B0（製造欠陥検出）
- 過去期間（2015-2018）のみで U-Net を **ランク2位** に抽出
- 将来期間（2019-2024）で B0 に314件出現を確認
- 全文類似ベースラインより候補の**説明可能性が高い**

実験2（補助分析：異質解決策型）

- 洗浄・除去系技術 → 半導体洗浄
- 46件中 ◎+○ = **16件（35%）** が有効
- 半導体基板洗浄クラスター：6件全て有効
- **クラスター設計**が候補品質に大きく影響

✓ 課題文脈と解決手段文脈を分離することで、「何の課題に近いのか」「どの解決手段が候補なのか」を説明しやすい専門家確認候補を抽出できることを確認した

キーワード

特許文書 / 課題・解決手段分離 / クロドメイン / 技術候補抽出 / LLM

参考：GapScoreの再掲

$$\text{GapScore}_m = \text{sim}^{\text{prob}}(A_0, B_0) \times \frac{\text{gap}_m}{\max \text{gap}} \times \log(1 + N_{A,m}) \times \min\left(\frac{1}{\text{rate}_{B,m} + \varepsilon}, C\right)$$

提案手法の位置づけ

提案手法は、課題・解決手段の分離、
→ 課題・解決手段の分離
を最近のLLMの性能を絞り込み（スクリーニング）
→
専門家評価 → 技術的・事業的評価

本研究はスクリーニング前段階の手法であり、その後の専門家評価と組み合わせて活用することを前提とする

ご清聴ありがとうございました

発表資料

- 論文 : `thesis/main.pdf`
- 実験レポート : [docs/experiment_report.md](#)
- 提案手法説明 : [pipeline/proposed_method_description.md](#)
- 実験設計説明 : [pipeline/experiment_design_description.md](#)
- 評価指標説明 : [pipeline/evaluation_metrics_description.md](#)

質問・コメントをお待ちしています